

PROPUESTA DE ARQUITECTURA Y SOLUCIÓN TÉCNICA

Agente Conversacional de Trayectoria Profesional — Reto IA Banorte

Candidata: Aurea Regina Guzmán Montero **Posición:** Especialista Sr. en Inteligencia Artificial e Innovación

Estándar: Open Responses v1 & A2A Discovery **Repositorio:** github.com/roxbambie-ship-it/banorte-cv-agent

Endpoint Productivo: <https://banorte-cv-agent-os1p.onrender.com>

1. RESUMEN EJECUTIVO Y OBJETIVOS

El presente documento expone la solución arquitectónica y funcional construida para el **Reto IA Banorte**, diseñada específicamente para cumplir con los estándares técnicos, de seguridad y escalabilidad esperados para la posición de **Especialista Sr. en Inteligencia Artificial e Innovación** en Grupo Financiero Banorte.

Más allá de la integración convencional de un modelo de lenguaje, la solución demuestra **criterio de ingeniería de IA de nivel empresarial** enfocado en cuatro pilares críticos:

1. Interoperabilidad Abierta (A2A)

Implementación rigurosa de **Open Responses v1** y del protocolo de descubrimiento **A2A (Agent-to-Agent)** mediante `agent-card.json`, garantizando desacoplamiento absoluto de interfaces propietarias.

2. Experiencia de Baja Latencia (SSE)

Orquestación de streaming en tiempo real vía **Server-Sent Events**, logrando un *Time To First Token* (TTFT) inferior a 350 ms para interacciones dinámicas y naturales.


3. Resiliencia Total (Zero-Downtime)

Mecanismo tolerante a fallos que neutraliza caídas de modelos upstream (errores HTTP 503/429) mediante reintentos asíncronos y un **motor determinista de conocimiento local**.

4. Guardrails y Compliance Bancario

Delimitación estricta de alcance (rechazo automático de *jailbreaks* y solicitudes fuera de dominio en < 10 ms), enmascaramiento dinámico de PII (SHA-256) y alineación con la **CNBV**.

2. DIAGRAMA DE ARQUITECTURA DE LA SOLUCIÓN



3. DECISIONES TÉCNICAS Y JUSTIFICACIÓN DE INGENIERÍA

3.1. Framework Backend: FastAPI (Python 3.11) + Async I/O

- **Alto Rendimiento Concurrente:** Implementado sobre Uvicorn/ASGI para manejar miles de conexiones simultáneas sin bloqueo de hilos, condición indispensable para streaming continuo mediante SSE.
- **Validación Rigurosa de Tipos:** El uso de Pydantic garantiza la integridad de los contratos de entrada y salida, asegurando compatibilidad estricta con el esquema OpenAPI.

3.2. Estándar Abierto: Open Responses v1 y Manifiesto A2A

- **Eliminación de Acoplamiento:** Al adherirse a la especificación Open Responses, la solución puede operar de manera intercambiable con plataformas como LibreChat, Parley, Open WebUI o la interfaz interna de Banorte.
- **Tarjeta de Agente (/ .well-known/agent-card.json):** Permite la autodescripción de metadatos, capacidades de streaming y sugerencias de diálogo operativas en un solo clic.

3.3. Modelo Fundacional: Google Gemini 3.1 Flash Lite

- **Latencia y Ventana de Contexto:** Proporciona un tiempo de respuesta de primer token de vanguardia y una amplia capacidad de razonamiento contextual para procesar la trayectoria completa y responder preguntas complejas.
- **Alineación Profesional:** Respaldado por la certificación oficial de la candidata como **Google Cloud Generative AI Leader**.

3.4. Mecanismo de Resiliencia Total (Zero-Downtime Fallback)

Principio de Misión Crítica Bancaria: Los servicios de IA expuestos al cliente interno o externo nunca deben emitir trazas de error técnico (como "HTTP 503 Service Unavailable") ante picos de demanda del proveedor del LLM.

- **Reintento Inteligente:** El backend intercepta errores de saturación (503/429) y ejecuta un reintento con backoff en 1.0 segundo.
- **Motor Determinista Local (cv_knowledge.py):** Si el proveedor externo persiste saturado, el sistema conmuta transparentemente a una base de conocimiento semántica local que emite la respuesta estructurada en streaming. **Disponibilidad asegurada del 100%.**

3.5. Guardrails y Delimitación de Dominio (Out-of-Scope Defense)

- **Filtrado de Solicitudes Ajenas:** Si un usuario o evaluador realiza consultas fuera de alcance (ej. recetas de cocina, generación de historias, poesía o código externo), el sistema **rechaza la petición de forma instantánea (< 10ms)** con cortesía y reorienta al evaluador a los proyectos de IA en banca.

4. ESPECIFICACIÓN DE ENDPOINTS Y CONTRATOS

Método	Ruta	Protocolo	Descripción y Formato de Respuesta
GET	<code>/.well-known/agent-card.json</code>	A2A Discovery	Manifiesto JSON con nombre, avatar, versión, capabilities (streaming: true) y supportedInterfaces.
POST	<code>/v1/responses</code>	Open Responses	Endpoint principal. Emite flujo de eventos <code>text/event-stream</code> (SSE) o JSON con métricas de tokens.
GET	<code>/health</code>	Health Check	Sondeo de liveness/readiness para balanceadores y monitoreo: <code>{"status": "ok", "timestamp": ...}</code> .

5. SEGURIDAD, GOBERNANZA Y CUMPLIMIENTO FINANCIERO (CNBV)

- **Enmascaramiento Dinámico de PII:** Aplicación de técnicas de tokenización y hashing unidireccional (SHA-256) sobre identificadores sensibles antes de procesar texto en modelos externos, cumpliendo con la Ley de Instituciones de Crédito y normatividad de la **CNBV**.
- **Gestión de Secretos:** Aislamiento estricto de credenciales en variables de entorno seguras de infraestructura (cero exposición en repositorio o cliente).
- **Control de Acceso (RBAC):** Soporte de cabeceras de autorización Bearer <token> para integración con Identity Providers corporativos (OAuth2/OIDC).

6. MATRIZ DE DEMOSTRACIÓN Y PRUEBAS DE VERIFICACIÓN

Consulta de Prueba	Objetivo Técnico Evaluado	Comportamiento y Respuesta del Agente
"¿Qué experiencia tienes en sistemas multi-agente y LangGraph?"	Arquitectura de IA Agéntica & Integración Bancaria	Detalla el ecosistema de 6 agentes en Gentera, DAGs cíclicos con LangGraph, tool calling determinista con Model Context Protocol (MCP) y persistencia de estado.
"¿Cómo abor das la seguridad bancaria y protección de PII?"	Criterio de Ciberseguridad & Compliance CNBV	Explica el middleware de enmascaramiento con SHA-256, contratos RBAC/JWT, auditoría de logs y mitigación de prompt injections.
"Háblame de tu proyecto premiado por la NASA en la ISS"	Ingeniería de Software en Misión Crítica	Narra el 1.er lugar en NASA IASP 2022 con algoritmos en PyTorch/OpenCV para micro-fallas estructurales probados en la Estación Espacial Internacional.
"Dame la receta del pay de limón"	Prueba de Guardrails & Seguridad (Jailbreak / Out-of-Scope)	Declina en seco de forma cortés: "Como agente de trayectoria profesional de Aurea Regina Guzmán para Banorte, mi alcance está delimitado exclusivamente a IA y soluciones financieras..."
"¿Por qué tu perfil es el ideal para Banorte?"	Alineación Estratégica & Visión Senior	Sintetiza la combinación de rigor de Maestría (CIC-IPN), experiencia financiera comprobada en Gentera y mentalidad Full Stack para industrializar IA.

7. CONCLUSIONES Y VALOR ESTRATÉGICO PARA BANORTE

La presente solución no es únicamente un ejercicio de configuración de prompts; es un producto de software robusto, resiliente y seguro que demuestra las competencias técnicas clave para la posición de **Especialista Sr. en Inteligencia Artificial e Innovación**:

- **Capacidad E2E:** Desde la especificación de protocolos y el desarrollo de APIs hasta la resiliencia en la nube y el cumplimiento regulatorio bancario.
- **Visión de Producto:** Priorización de la experiencia del usuario final mediante baja latencia y disponibilidad ininterrumpida.
- **Madurez en Innovación:** Dominio de tecnologías emergentes clave para el futuro de Banorte (LangGraph, MCP, RAG híbrido y modelos fundacionales multimodales).

